


Introducción a Reinforcement Learning

Aprendizaje por Refuerzo
2026



Reglas Básicas

- Time is money
 - Puntualidad y Costo oportunidad
- Considerar a los demás
 - Actividades silenciosas en el salón de clase
- Respeto
 - Libertad de preguntar
 - Aportar y debatir ideas
 - Ambiente de aprendizaje
- Fechas de entrega
 - Cambio por todo el grupo
 - No se aceptan entregas atrasadas sin previa autorización
- Asistencia y Participación
 - No son obligatorias
 - Son importantes

El Pipeline General



/albertosuriano/



lasuriano@uvg.edu.gt

Presentación

- ¿Qué me pueden decir de ustedes?
 - Nombre
 - ¿Qué saben de Aprendizaje por Refuerzo?

Sobre el Curso

Actividades

- Laboratorios – 5 – (6pts c/u)
- Hojas de Trabajo – 2 – (3pts c/u)
- Proyectos Intermedio – 1 – (18pts)
- Examen Práctico – 1 – (16pts)
- Proyecto Final – 1 – (30 pts)

La mayor parte del tiempo...


- El primer día (MARTES) tendremos la clase teórica
 - Presentar el tema actual
 - Solucionar preguntas del tema anterior
 - Solucionar dudas del laboratorio
- El segundo día (JUEVES) se dedicará principalmente al laboratorio
- Virtual
 - **NO** es necesario que vengan presencialmente
 - Discord

Propósito del Curso

- Bases para entender Reinforcement Learning
- Se ejercitará sus habilidades de análisis, abstracción e implementación de soluciones genéricas a problemas dados
 - Dado un problema de aplicación, sepa cómo (y si) usar RL para ello.
 - Implementar (en código) algoritmos RL comunes
- Entender mejor este campo
 - Comprender los enfoques teóricos y empíricos para evaluar la calidad de un algoritmo RL.

Bibliografía

- “Reinforcement Learning: An Introduction” de Richard S. Sutton y Andrew G. Barto



Introducción a Reinforcement Learning

¿Por qué RL?

- Un sistema de trading toma miles de decisiones por día, ¿cómo aprende si cada acción afecta el mercado?
- Un robot quirúrgico ajusta su fuerza milímetro a milímetro, ¿dónde está el "label" correcto?
- Un modelo de lenguaje decide token por token cuál respuesta completa mejor una consulta
- **Punto común:** decisiones secuenciales donde el feedback es tardío, ruidoso o ausente
- RL es la rama del ML diseñada específicamente para este tipo de problema

RL en el mapa del aprendizaje automático

- **Supervisado:** aprende de pares (x, y) etiquetados por un oráculo externo
- **No supervisado:** descubre estructura latente sin etiquetas
- **RL:** aprende de la interacción, sin oráculo, solo señal de recompensa
- Diferencia clave: en RL el agente **influye** en los datos que recibe
- Segunda diferencia clave: en RL los errores tienen **consecuencias futuras**

El ciclo agente-entorno

- El agente observa el estado S_t del entorno
- Selecciona una acción A_t según su política
- El entorno transiciona a un nuevo estado S_{t+1}
- El entorno emite una recompensa R_{t+1}
- El ciclo se repite, esto es un **paso de tiempo** (*timestep*)
- La interacción produce una **trayectoria**: $S_0, A_0, R_1, S_1, A_1, R_2, \dots$

Estado, observación y espacio de acciones

- **Estado S_t :** representación completa del entorno (puede ser inaccesible)
- **Observación O_t :** lo que el agente realmente percibe (puede ser parcial)
- **Entorno totalmente observable:** $O_t = S_t \rightarrow \text{MDP}$
- **Entorno parcialmente observable:** $O_t \neq S_t \rightarrow \text{POMDP}$
- **Espacio de acciones $\mathcal{A}$:** conjunto de acciones disponibles
 - Discreto: {arriba, abajo, izquierda, derecha}
 - Continuo: torque $\in [-5, 5]\text{Nm}$

Recompensa y la hipótesis de recompensa

- La recompensa $R_t \in \mathbb{R}$ es una señal escalar del entorno
- **Hipótesis de recompensa** (Sutton & Barto): todo objetivo puede expresarse como maximización de recompensa acumulada esperada
- La recompensa es **señal de diseño**, no dato observado
- Ejemplos industriales:
 - Banca: +1 si el crédito se paga, -1 si entra en mora
 - Telecomunicaciones: recompensa proporcional al throughput del canal
 - Salud: días sin síntomas como proxy de bienestar del paciente

Política, el cerebro del agente

- La **política** π define el comportamiento del agente
- **Determinista:** $\pi(s) = a$, mapea estado a acción
- **Estocástica:** $\pi(a | s) = P(A_t = a | S_t = s)$, distribución sobre acciones
- La política es el **objeto que RL optimiza**
- No es una regla fija, evoluciona durante el entrenamiento

Retorno, el objetivo a largo plazo

- El agente maximiza el **retorno** G_t , no la recompensa inmediata
- **Retorno sin descuento** (episodios finitos): $G_t = \sum_{k=0}^{T-t-1} R_{t+k+1}$
- **Retorno con descuento** (horizonte infinito): $G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$
- $\gamma \in [0, 1]$: **factor de descuento** — cuánto importa el futuro
 - $\gamma \rightarrow 0$: agente miope (solo recompensa inmediata)
 - $\gamma \rightarrow 1$: agente con visión de largo plazo

Funciones de valor, evaluar estados y acciones


- **Función de valor de estado** $V^\pi(s)$: retorno esperado desde s siguiendo π
- **Función de valor de acción** $Q^\pi(s, a)$: retorno esperado desde s , tomando a , luego siguiendo π
- $V^\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s]$
- $Q^\pi(s, a) = \mathbb{E}_\pi[G_{t'} \mid S_t = s, A_t = a]$
- Relación fundamental: $V^\pi(s) = \sum_a \pi(a \mid s) \cdot Q^\pi(s, a)$

Resumen del marco conceptual

- **Agente:** tomador de decisiones con política π
- **Entorno:** mundo que transiciona y emite recompensas
- **Estado S_t :** información del mundo en el tiempo t
- **Acción A_t :** decisión del agente
- **Recompensa R_{t+1} :** señal escalar de retroalimentación
- **Retorno G_t :** suma descontada de recompensas futuras, el objetivo real
- **Funciones de valor V^π , Q^π :** estimación del retorno esperado

RL vs Supervisado vs No Supervisado

Dimensión	Supervisado	No supervisado	Reinforcement Learning
Señal de aprendizaje	Etiqueta y por ejemplo	Ninguna	Recompensa escalar R_t
Origen de los datos	Dataset fijo	Dataset fijo	Interacción con el entorno
El agente afecta los datos	No	No	Sí
Horizonte temporal	Un paso	Un paso	Múltiples pasos
Problema central	Generalización	Representación	Asignación de crédito temporal
Ejemplo industrial	Clasificación de fraude	Segmentación de clientes	Optimización de portafolio



¡Gracias!